# 04
# 로지스틱 회귀

둘 중 하나를 고르는 이진 분류 문제를, 확률을 계산하는 방식으로 푸는 로지스틱 회귀의 이론을 세우고 실제 상황에 적용해 봅니다.

### 오늘 다루는 것

1. 로지스틱 회귀: 이진 분류, 시그모이드, 결정 경계, 이진 크로스 엔트로피
2. nn.Module과 클래스로 구현하는 로지스틱 회귀

### 끝나고 나면 할 수 있는 것

1. 이진 분류, 시그모이드 함수, 결정 경계, 이진 크로스 엔트로피를 정의하고 식으로 쓸 수 있다.
2. 선형 회귀를 분류에 그대로 쓰면 안 되는 이유를 출력 범위와 손실 함수의 관점에서 설명할 수 있다.
3. 정의한 개념을 실제 문제(강아지/고양이 판별)에 적용해 파이토치로 학습시키고 결과를 해석할 수 있다.

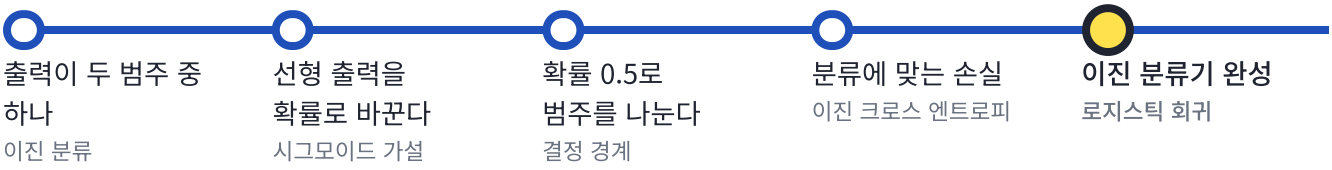
2026년 10월 6일 화요일 (10/6 자료 2/3)
발표자 설명, 코랩 실습, 퀴즈 돌아가며 풀기 순서로 진행합니다. 막힌 질문은 디스코드에 남겨 주세요.

# 04

# 로지스틱 회귀

03장의 선형 회귀는 연속된 숫자를 예측했습니다. 이 장에서는 출력이 **두 범주 중 하나**인 문제, 즉 이진 분류를 다룹니다. 로지스틱 회귀는 선형 회귀의 점수 $Wx + b$를 0과 1 사이의 확률로 바꾸고, 분류에 맞는 손실 함수로 학습합니다. 예측 → 손실 → 경사하강법이라는 03장의 뼈대는 그대로이고, **가설**과 **손실 함수** 두 가지만 바뀝니다.

## 왜 배우나: 오늘의 학습 경로




각 개념은 먼저 **정의**로 세운 뒤, 한 가지 실제 상황에 **적용**해 확인합니다. 이 장의 적용 상황은 "동물병원 접수 앱: 몸무게와 주둥이 길이로 강아지와 고양이를 판별하기"입니다.

# 04-01 로지스틱 회귀

핵심 한 줄

**로지스틱 회귀는 선형 점수 $Wx + b$를 시그모이드로 0~1의 확률로 바꿔 이진 분류를 하고, 이진 크로스 엔트로피를 최소화하도록 W와 b를 학습하는 모델이다.**

왜 배우나

분류는 머신 러닝에서 가장 흔한 문제입니다. 스팸 메일 판별, 리뷰의 긍정/부정 판단(13장), 다음 단어 고르기(21장)가 모두 분류입니다. 로지스틱 회귀는 그중 가장 단순한 형태인 이진 분류의 기본 모델이고, 여기서 정의하는 시그모이드와 크로스 엔트로피는 06장 이후의 모든 분류 신경망에 그대로 쓰입니다.

## 1) 이진 분류

정의

이진 분류(Binary Classification)는 입력 $x$를 보고 출력을 **두 범주 중 하나**로 정하는 문제입니다. 두 범주에 각각 숫자 레이블 $y \in \{0, 1\}$을 붙이고, 1인 쪽을 보통 "양성(positive)", 0인 쪽을 "음성(negative)"이라고 부릅니다.

- 입력 $x$는 여러 개의 **특성(feature)**으로 이루어진 벡터입니다: $x = (x_1, x_2, \ldots, x_d)$
- 모델은 정답 범주 자체가 아니라 $y = 1$**일 확률** $P(y = 1 \mid x)$을 출력하고, 이 확률로 범주를 정합니다.

예시 적용

동물병원 접수 앱에서 입력은 특성 2개, $x = (\text{몸무게}, \text{주둥이 길이})$이고, 레이블은 강아지 $y = 1$, 고양이 $y = 0$입니다. 학습 데이터는 동물 10마리이며, 고양이만큼 작은 치와와와 강아지만큼 큰 메인쿤처럼 헷갈리는 사례도 들어 있습니다.

| 동물 | 몸무게 (kg) | 주둥이 (cm) | y | 동물 | 몸무게 (kg) | 주둥이 (cm) | y |
|---|---|---|---|---|---|---|---|
| 코리안숏헤어 | 4.0 | 2.5 | 0 | 포메라니안 | 2.5 | 4.0 | 1 |
| 페르시안 | 4.5 | 2.0 | 0 | 치와와 | 2.0 | 3.5 | 1 |
| 러시안블루 | 3.5 | 3.0 | 0 | 시바견 | 9.0 | 7.0 | 1 |
| 스코티시폴드 | 3.8 | 2.2 | 0 | 진돗개 | 15.0 | 8.5 | 1 |
| 메인쿤 | 8.0 | 3.5 | 0 | 골든리트리버 | 25.0 | 10.0 | 1 |

## 2) 시그모이드 함수와 가설

정의

**선형 회귀를 그대로 쓸 수 없는 이유.** 선형 회귀의 출력 $Wx + b$는 $-\infty$부터 $+\infty$까지 어떤 값이든 될 수 있습니다. 하지만 확률은 반드시 0과 1 사이여야 합니다. 그래서 실수 전체를 (0, 1) 구간으로 옮겨 주는 함수가 필요합니다.

**시그모이드 함수(Sigmoid function)**는 다음과 같이 정의합니다.

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

- 출력 범위: 항상 $0 < \sigma(z) < 1$
- $\sigma(0) = 0.5$, $z \to +\infty$이면 1에, $z \to -\infty$이면 0에 가까워집니다.
- $z$가 커질수록 출력도 커집니다(증가 함수). 그래서 점수가 높을수록 확률이 높다는 순서가 유지됩니다.

**로지스틱 회귀의 가설**은 선형 점수를 시그모이드에 넣은 것입니다.

$$H(x) = \sigma(Wx + b) = \frac{1}{1 + e^{-(Wx+b)}} = P(y = 1 \mid x)$$

- $W$(가중치): 각 특성이 확률에 주는 영향의 방향과 크기. $|W|$가 클수록 S자가 가팔라집니다.
- $b$(편향): S자를 좌우로 옮겨, 확률이 0.5가 되는 지점을 정합니다.

예시 적용

주둥이 길이 하나만으로 강아지를 판별해 보면 차이가 분명합니다. 직선을 그으면 주둥이 10cm인 골든리트리버는 "강아지일 확률 1.4"라는 불가능한 값을 받지만, 시그모이드를 쓰면 $H(x)$는 언제나 0~1 사이의 "강아지일 확률"이 됩니다.

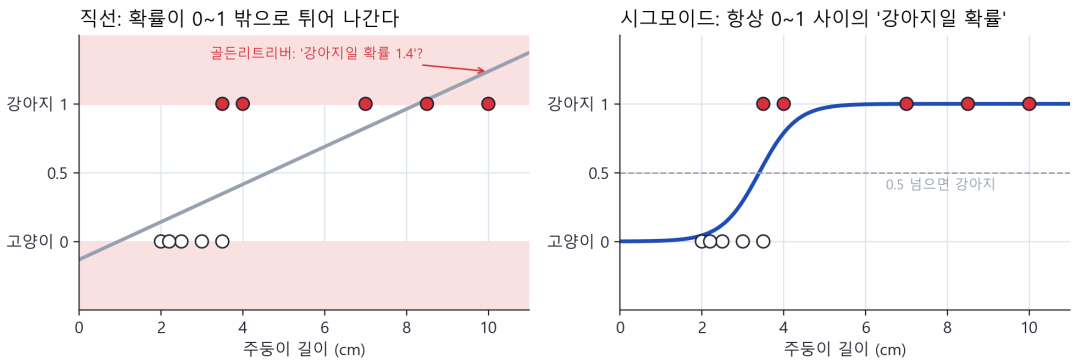



그림 1 빨간 점은 강아지(y = 1), 흰 점은 고양이(y = 0). 왼쪽: 직선은 0~1 밖(분홍)으로 벗어난다. 오른쪽: 시그모이드는 항상 확률 범위 안에 있다

W와 b의 정의도 이 상황의 말로 읽을 수 있습니다. W는 "주둥이가 1cm 길어질 때 강아지라는 확신이 얼마나 빨리 커지나", b는 "몇 cm부터 강아지 쪽으로 볼까"를 정합니다.

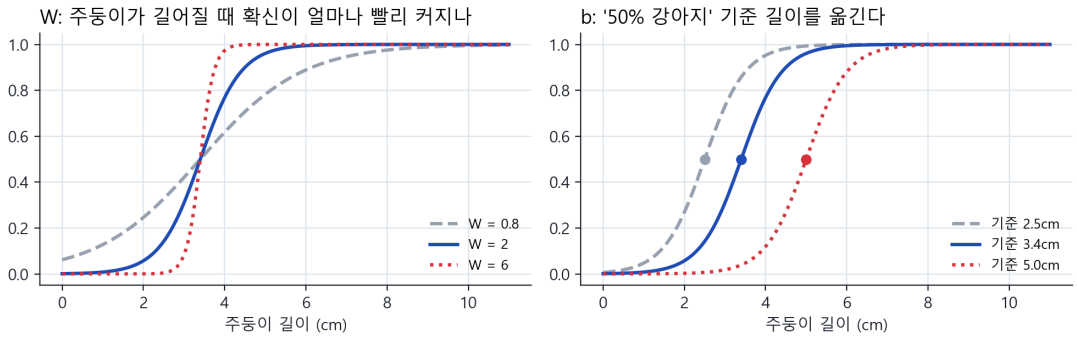



**그림 2** 왼쪽: W가 클수록 기준 근처에서 판단이 급격히 바뀐다. 오른쪽: b가 바뀌면 확률 0.5가 되는 기준 길이가 옮겨진다

## 3) 결정 경계

정의

확률을 범주로 바꾸려면 기준이 필요합니다. 보통 0.5를 기준으로 다음과 같이 예측합니다.

$$\hat{y} = \begin{cases} 1 & H(x) \geq 0.5 \\ 0 & H(x) < 0.5 \end{cases}$$

$\sigma(z) = 0.5$인 것은 $z = 0$일 때뿐이므로, 두 범주가 갈리는 지점은 $Wx + b = 0$입니다. 이 집합을 결정 경계(Decision Boundary)라고 합니다. 특성이 2개면 $w_1 x_1 + w_2 x_2 + b = 0$으로, 평면 위의 **직선**이 됩니다. 즉 로지스틱 회귀는 특성 공간을 직선(특성이 많으면 평면) 하나로 나누는 분류기입니다.

예시 적용

동물 10마리로 학습하면(실습 1) 몸무게-주둥이 평면 위에 경계선이 생깁니다. 선 위쪽은 강아지, 아래쪽은 고양이로 판단하며, 치와와와 메인쿤도 올바르게 나뉩니다.

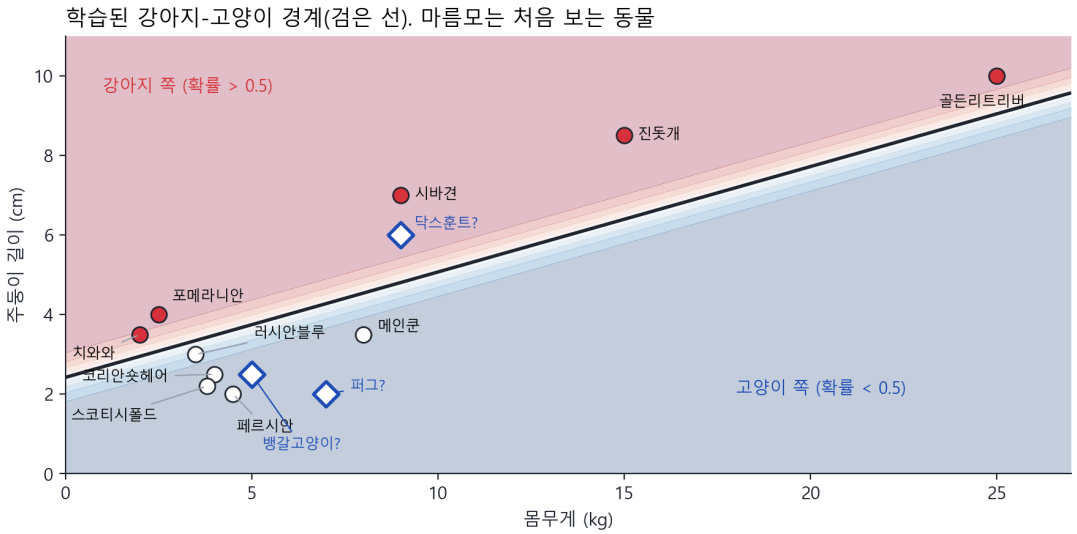



**그림 3** 학습된 결정 경계 $w_1 \cdot$ 몸무게 $+ w_2 \cdot$ 주둥이 $+ b = 0$(검은 선). 마름모는 04-02에서 판별할 처음 보는 동물

학습된 값은 $w_1 = -0.94$(몸무게), $w_2 = +3.57$(주둥이), $b = -8.63$입니다. 가중치의 정의대로 읽으면, 주둥이가 길수록 강아지 확률이 크게 오르고, 몸무게는 오히려 약간 반대 방향으로 작용합니다. 큰 고양이 메인쿤 때문에 "무겁다고 강아지는 아니다"를 배운 결과입니다.

## 4) 비용 함수: 이진 크로스 엔트로피

정의

**평균 제곱 오차를 쓰지 않는 이유.** 시그모이드 가설에 MSE를 쓰면 비용 함수가 볼록하지 않은(non-convex) 울퉁불퉁한 모양이 되어, 경사하강법이 전체 최솟값(global minimum)이 아닌 국소 최솟값(local minimum)에 멈출 수 있습니다.

**이진 크로스 엔트로피(Binary Cross-Entropy, BCE)**는 샘플 하나에 대해 다음과 같이 정의합니다.

$$\text{loss}(H, y) = \begin{cases} -\log H & y = 1 \\ -\log(1 - H) & y = 0 \end{cases}$$

- 정답이 1일 때 $H \to 1$이면 손실 $\to 0$, $H \to 0$이면 손실 $\to \infty$
- 정답이 0일 때는 그 반대. 즉 **정답과 반대쪽으로 확신할수록 손실이 급격히 커집니다.**

두 경우를 하나로 합치고 n개 샘플의 평균을 내면 로지스틱 회귀의 비용 함수가 됩니다.

$$\text{cost}(W, b) = -\frac{1}{n} \sum_{i=1}^{n} \left[ y^{(i)} \log H(x^{(i)}) + \left(1 - y^{(i)}\right) \log\left(1 - H(x^{(i)})\right) \right]$$

$y$가 1이면 앞 항만, 0이면 뒤 항만 남습니다. 이 비용 함수를 경사하강법으로 최소화하는 과정은 03장과 같습니다.

예시 적용

- 진짜 강아지($y = 1$)에게 "강아지일 확률 0.9"라고 했다면 손실은 $-\log 0.9 \approx 0.11$로 작습니다.
- 같은 강아지에게 "0.1"(고양이라고 확신)이라고 했다면 $-\log 0.1 \approx 2.30$으로 큽니다.
- 진짜 고양이($y = 0$)에게 "강아지일 확률 0.95"라고 했다면 $-\log 0.05 \approx 3.00$입니다.

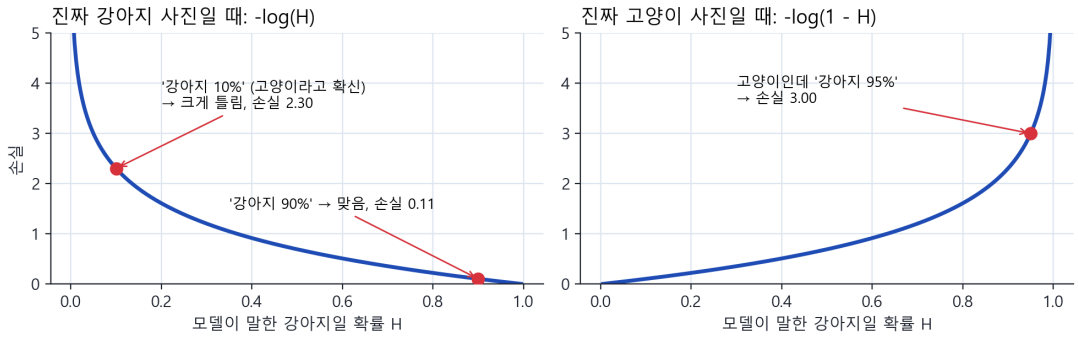



그림 4 정의의 두 경우를 그래프로 본 것. 정답과 반대쪽으로 확신할수록 손실이 치솟는다

비유

### 동물 맞히기 퀴즈쇼

참가자가 동물 사진의 일부만 보고 "강아지일 확률"을 퍼센트로 적어 냅니다. 정답에 가깝게 확신했다면 감점이 거의 없고, 애매하게 50%라고 했다면 중간쯤, 반대쪽으로 확신했다면 크게 감점됩니다. 참가자는 감점을 줄이도록 판단 기준을 조금씩 고쳐 나갑니다.

| | |
|---|---|
| **적어 낸 퍼센트** | = $H(x)$ |
| **실제 동물** | = 정답 $y$ |
| **감점표** | = 이진 크로스 엔트로피 |
| **판단 기준 고치기** | = 경사하강법으로 W, b 갱신 |

실습 1

## 정의대로 구현하기: 시그모이드 가설 + 이진 크로스 엔트로피

```
import torch
import torch.optim as optim

torch.manual_seed(1)
# 동물 10마리: [몸무게(kg), 주둥이 길이(cm)] → 강아지(1) / 고양이(0)
names = ["코리안숏헤어", "페르시안", "러시안블루", "스코티시폴드", "메인쿤",
         "포메라니안", "치와와", "시바견", "진돗개", "골든리트리버"]
x_train = torch.FloatTensor([[4.0, 2.5], [4.5, 2.0], [3.5, 3.0], [3.8, 2.2],
[8.0, 3.5],
                             [2.5, 4.0], [2.0, 3.5], [9.0, 7.0], [15.0, 8.
5], [25.0, 10.0]])
y_train = torch.FloatTensor([[0], [0], [0], [0], [1], [1], [1], [1],
[1]])

W = torch.zeros((2, 1), requires_grad=True)   # 특성 2개 → 가중치 2개
b = torch.zeros(1, requires_grad=True)
optimizer = optim.SGD([W, b], lr=0.1)

for epoch in range(3001):
    hypothesis = torch.sigmoid(x_train.matmul(W) + b)          # 강아지일 확
률 (0~1)
    # 이진 크로스 엔트로피: 강아지(1)면 -log(H), 고양이(0)면 -log(1-H)
    cost = -(y_train * torch.log(hypothesis) +
             (1 - y_train) * torch.log(1 - hypothesis)).mean()
    optimizer.zero_grad()
    cost.backward()
    optimizer.step()
    if epoch % 1000 == 0:
        print(f"Epoch {epoch:4d}  Cost: {cost.item():.4f}")

print(f"학습된 W: 몸무게 {W[0].item():.2f}, 주둥이 {W[1].item():.2f}  b: {b.it
em():.2f}")
prob = torch.sigmoid(x_train.matmul(W) + b).squeeze()
for name, p, y in zip(names, prob.tolist(), y_train.squeeze().tolist()):
    guess = "강아지" if p >= 0.5 else "고양이"
    answer = "강아지" if y == 1 else "고양이"
    print(f"{name:7s} 강아지일 확률 {p:.2f} → {guess}  (정답 {answer})")
```

실행 결과

```
Epoch    0  Cost: 0.6931
Epoch 1000  Cost: 0.1088
Epoch 2000  Cost: 0.0690
Epoch 3000  Cost: 0.0526
학습된 W: 몸무게 -0.94, 주둥이 3.57  b: -8.63
코리안숏헤어   강아지일 확률 0.03 → 고양이  (정답 고양이)
페르시안      강아지일 확률 0.00 → 고양이  (정답 고양이)
러시안블루     강아지일 확률 0.22 → 고양이  (정답 고양이)
스코티시폴드   강아지일 확률 0.01 → 고양이  (정답 고양이)
메인쿤       강아지일 확률 0.02 → 고양이  (정답 고양이)
포메라니안     강아지일 확률 0.96 → 강아지  (정답 강아지)
치와와       강아지일 확률 0.88 → 강아지  (정답 강아지)
시바견       강아지일 확률 1.00 → 강아지  (정답 강아지)
진돗개       강아지일 확률 1.00 → 강아지  (정답 강아지)
골든리트리버   강아지일 확률 0.97 → 강아지  (정답 강아지)
```

직접 해 보기 러시안블루의 강아지일 확률(0.22)이 고양이 중 가장 높은 이유를 결정 경계의 식 $w_1x_1 + w_2x_2 + b$로 설명해 보세요. 주둥이 길이가 다른 고양이보다 어떤가요?

확인 문제

## 04-01 확인 문제 한 명씩 돌아가며 풀고, 푼 사람 이름을 적어 주세요

**1** 시그모이드 함수의 출력은 항상 0과 1 사이다. (O / X) 이름 _____

**2** 로지스틱 회귀의 결정 경계는 $Wx + b = 0$인 곳이다. (O / X) 이름 _____

**3** 선형 회귀의 출력을 확률로 쓸 수 없는 가장 큰 이유는? 이름 _____

① 계산이 느려서 ② 출력이 0~1 범위를 벗어날 수 있어서 ③ 가중치가 없어서

**4** 정답이 1인 샘플에 $H = 0.1$로 예측했을 때 이진 크로스 엔트로피 손실은? 이름 _____

① 약 0.11 ② 약 2.30 ③ 정확히 0

**5** $\sigma(0)$의 값은 _____이다. 이름 _____

**6** 예시에서 강아지 판별에 가장 큰 양의 가중치를 받은 특성은 _____이다. 이름 _____

**7** 이진 크로스 엔트로피의 정의를 말하고, 강아지/고양이 예시에 적용해 설명해 보세요. 이름 _____

원문: 04-01 로지스틱 회귀 — https://wikidocs.net/57805 (이론은 교재를 따르고, 적용 예시를 강아지/고양이 판별로 바꿨습니다)

# 04-02 nn.Module과 클래스로 구현하는 로지스틱 회귀

핵심 한 줄 **로지스틱 회귀는 nn.Linear(선형 점수)와 nn.Sigmoid(확률 변환)를 이은 모델이며, 이는 인공 신경망의 뉴런 하나와 같은 구조다.**

왜 배우나 04-01에서 정의대로 직접 구현한 모델을 파이토치 도구로 다시 씁니다. 이 형태가 06장 이후 모든 신경망 코드의 기본 모양이고, 학습된 모델을 처음 보는 데이터에 적용(추론)하는 방법과 그때 드러나는 모델의 한계도 함께 확인합니다.

## 1) 파이토치 구성 요소

정의

- nn.Linear(in, out): 가중치 $W$(크기 in × out)와 편향 $b$를 가진 선형 변환 $Wx + b$. 이진 분류에서는 out = 1입니다.
- nn.Sigmoid(): 각 값에 $\sigma(z)$를 적용합니다.
- F.binary_cross_entropy(H, y): 04-01의 비용 함수(이진 크로스 엔트로피 평균)를 계산합니다.
- nn.Module 클래스: `__init__` 에 층을 정의하고, `forward` 에 입력이 층을 지나는 순서를 정의합니다.

뉴런으로 보기. 입력에 가중치를 곱해 더하고($\sum_j w_j x_j + b$) 활성화 함수(시그모이드)를 적용하는 구조는 인공 신경망의 **뉴런** 하나와 같습니다. 로지스틱 회귀는 뉴런이 하나뿐인 신경망입니다.

예시 적용 강아지/고양이 판별기에서는 입력 특성이 2개(몸무게, 주둥이 길이)이므로 `nn.Linear(2, 1)`, 그 뒤에 `nn.Sigmoid()`를 이어 `DogCatClassifier` 클래스를 만듭니다.

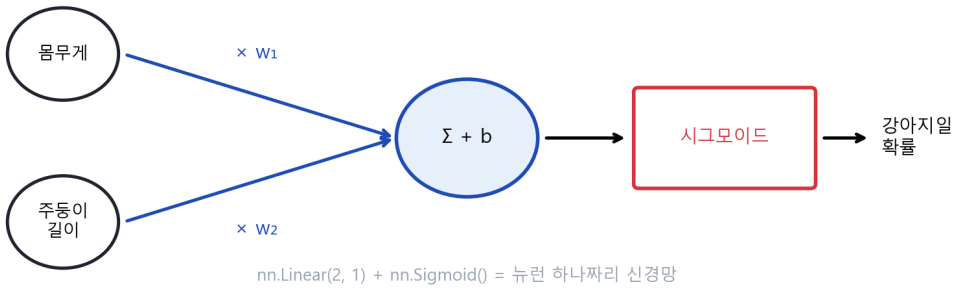



그림 5 강아지/고양이 판별기를 뉴런으로 그린 그림. 특성에 가중치를 곱해 더하고(Σ + b), 시그모이드로 강아지일 확률을 낸다

## 2) 추론과 모델의 한계

정의

추론(Inference)은 학습이 끝난 모델에 처음 보는 입력을 넣어 예측을 얻는 것입니다. 이때는 기울기가 필요 없으므로 `torch.no_grad()` 안에서 실행합니다.

특성의 한계. 모델은 오직 입력 특성의 선형 결합 $Wx + b$로만 판단합니다. 그래서 두 범주를 가르는 정보가 특성에 없거나, 두 범주가 직선 하나로 나뉘지 않으면 올바르게 분류할 수 없습니다. 이 한계를 넘는 방법이 더 좋은 특성을 추가하거나, 층을 쌓아 굽은 경계를 만드는 것(06장)입니다.

예시 적용

학습에 쓰지 않은 세 동물을 추론하면, 닥스훈트(9kg, 주둥이 6cm)는 강아지, 뱅갈고양이(5kg, 2.5cm)는 고양이로 맞힙니다. 하지만 **퍼그**(7kg, 주둥이 2cm)는 강아지인데 "강아지일 확률 0.00"으로 고양이라고 판단합니다. 퍼그는 주둥이가 짧은 강아지라서, 주둥이 길이에 크게 의존하는 이 모델의 결정 경계로는 나눌 수 없습니다. 정의에서 말한 "특성의 한계"가 그대로 나타난 사례입니다. 귀 모양처럼 강아지와 고양이를 더 잘 가르는 특성이 있다면 퍼그도 맞힐 수 있습니다.

비유

### 질문이 두 개뿐인 접수 직원

몸무게와 주둥이 길이만 묻고 진료실을 안내하는 접수 직원은, 주둥이가 짧은 퍼그 보호자를 고양이 진료실로 보냅니다. 직원의 판단 방식이 아니라 묻는 질문(특성)이 부족한 것입니다.

**접수 직원 한 명** = 뉴런 하나 = 로지스틱 회귀
**묻는 질문** = 입력 특성
**진료실 안내** = 추론 (확률 0.5 기준)

## 실습 2 nn.Module로 구현하고 처음 보는 동물 추론하기

```
import torch
import torch.nn as nn
import torch.nn.functional as F

torch.manual_seed(1)
# [몸무게(kg), 주둥이 길이(cm)] → 강아지(1) / 고양이(0)
x_train = torch.FloatTensor([[4.0, 2.5], [4.5, 2.0], [3.5, 3.0], [3.8, 2.2],
[8.0, 3.5],
                             [2.5, 4.0], [2.0, 3.5], [9.0, 7.0], [15.0, 8.
5], [25.0, 10.0]])
y_train = torch.FloatTensor([[0], [0], [0], [0], [0], [1], [1], [1], [1],
[1]])

# 강아지-고양이 판별기 설계도: 선형 층 하나 + 시그모이드
class DogCatClassifier(nn.Module):
    def __init__(self):
        super().__init__()
        self.linear = nn.Linear(2, 1)      # 특성 2개 → 점수 1개 (W와 b 자동 생
성)
        self.sigmoid = nn.Sigmoid()        # 점수 → 강아지일 확률

    def forward(self, x):
        return self.sigmoid(self.linear(x))

model = DogCatClassifier()
optimizer = torch.optim.SGD(model.parameters(), lr=0.1)

for epoch in range(3001):
    hypothesis = model(x_train)
    cost = F.binary_cross_entropy(hypothesis, y_train)   # 이진 크로스 엔트로
피 한 줄로
    optimizer.zero_grad()
    cost.backward()
    optimizer.step()
    if epoch % 1000 == 0:
        accuracy = ((hypothesis >= 0.5).float() == y_train).float().mean()
        print(f"Epoch {epoch:4d}  Cost: {cost.item():.4f}  정확도: {accuracy.
item() * 100:.0f}%")

# 처음 보는 동물 사진이 들어왔다면?
new_animals = {"닥스훈트 (9kg, 주둥이 6cm)": [9.0, 6.0],
               "뱅갈고양이 (5kg, 주둥이 2.5cm)": [5.0, 2.5],
               "퍼그 (7kg, 주둥이 2cm)": [7.0, 2.0]}
with torch.no_grad():
    for name, feat in new_animals.items():
        p = model(torch.FloatTensor([feat])).item()
        print(f"{name}: 강아지일 확률 {p:.2f} → {'강아지' if p >= 0.5 else '고
양이'}")
```

실행 결과

```
Epoch    0  Cost: 0.8219  정확도: 30%
Epoch 1000  Cost: 0.1088  정확도: 100%
Epoch 2000  Cost: 0.0690  정확도: 100%
Epoch 3000  Cost: 0.0527  정확도: 100%
닥스훈트 (9kg, 주둥이 6cm): 강아지일 확률 0.99 → 강아지
뱅갈고양이 (5kg, 주둥이 2.5cm): 강아지일 확률 0.01 → 고양이
퍼그 (7kg, 주둥이 2cm): 강아지일 확률 0.00 → 고양이
```

직접 해 보기 학습 데이터에 퍼그 `[7.0, 2.0]` (y = 1)를 추가해 다시 학습시켜 보세요. 직선 하나로 모든 동물을 나눌 수 있나요? 정의의 "특성의 한계"와 연결해 보세요.

### 3) 범주가 셋 이상이면

정의

> 시그모이드 출력은 $P(y=1 \mid x)$ 하나뿐이고, 나머지 범주의 확률은 $1 - H(x)$로 정해집니다. 그래서 범주가 셋 이상인 다중 클래스 분류에는 범주마다 점수를 내고 그 점수들을 합이 1인 확률로 바꾸는 소프트맥스 회귀(05장)를 씁니다.

예시 적용

접수 앱에 원숭이까지 온다면 "강아지일 확률" 하나로는 부족하고, 강아지·고양이·원숭이 각각의 확률이 필요합니다.

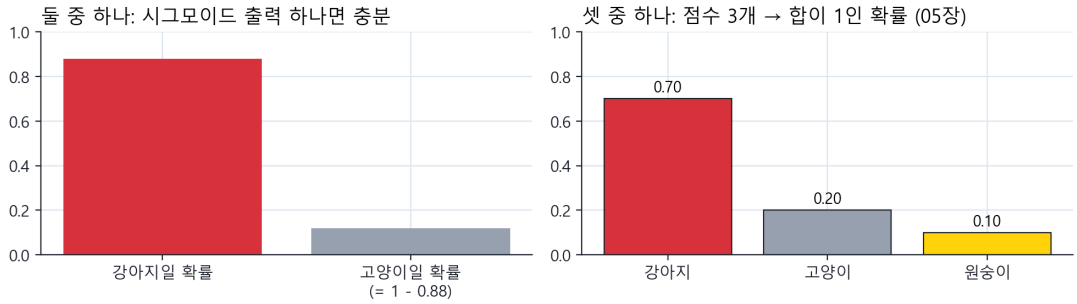



그림 6 왼쪽: 이진 분류는 확률 하나로 충분하다. 오른쪽: 세 범주는 합이 1인 확률 세 개가 필요하다(05장 소프트맥스)

확인 문제

## 04-02 확인 문제 한 명씩 돌아가며 풀고, 푼 사람 이름을 적어 주세요

**1** 로지스틱 회귀는 뉴런 하나짜리 신경망으로 볼 수 있다. (O / X) 이름 _____

**2** 로지스틱 회귀는 직선으로 나눌 수 없는 범주도 항상 정확히 분류한다. (O / X) 이름 _____

**3** 학습이 끝난 모델에 처음 보는 입력을 넣어 예측하는 것은? 이름 _____

① 추론 ② 역전파 ③ 정규화

**4** 예시에서 모델이 잘못 판단한 동물과 그 이유로 알맞은 것은? 이름 _____

① 닥스훈트, 몸무게가 무거워서 ② 퍼그, 주둥이가 짧아 특성만으로는 고양이와 구분되지 않아서 ③ 뱅갈고양이, 데이터가 없어서

**5** 특성이 2개인 이진 분류의 선형 층은 nn.Linear(_____, 1)이다. 이름 _____

**6** 범주가 셋 이상인 분류에는 _____ 회귀를 쓴다. 이름 _____

**7** "특성의 한계"를 정의하고, 퍼그 사례에 적용해 설명해 보세요. 이름 _____

원문: 04-02 nn.Module과 클래스로 구현하는 로지스틱 회귀 — https://wikidocs.net/58686

# 오늘의 요약

다시 보기




정의 모음

| 개념 | 정의 | 강아지/고양이 예시 |
|---|---|---|
| 이진 분류 | 입력을 두 범주($y \in \{0, 1\}$) 중 하나로 정하는 문제 | 강아지 1, 고양이 0 |
| 시그모이드 | $\sigma(z) = 1/(1 + e^{-z})$, 출력 0~1, $\sigma(0) = 0.5$ | 점수를 "강아지일 확률"로 |
| 가설 | $H(x) = \sigma(Wx + b) = P(y = 1 \mid x)$ | 몸무게·주둥이로 강아지일 확률 계산 |
| 결정 경계 | $Wx + b = 0$, 특성 2개면 직선 | 몸무게-주둥이 평면의 경계선 |
| 이진 크로스 엔트로피 | $y = 1$이면 $-\log H$, $y = 0$이면 $-\log(1 - H)$ | 강아지에게 0.1이라 하면 손실 2.30 |
| 특성의 한계 | 선형 결합으로만 판단하므로 특성에 정보가 없으면 못 나눈다 | 주둥이 짧은 퍼그를 고양이로 판단 |

다음

### 다음 자료 예고: 05장 소프트맥스 회귀

범주가 셋 이상인 다중 클래스 분류를 다룹니다. 소프트맥스 함수와 크로스 엔트로피를 정의하고, 강아지·고양이·원숭이처럼 여러 범주의 확률을 한꺼번에 계산합니다.

# 정답과 해설

## 04-01 로지스틱 회귀

1. O — $0 < \sigma(z) < 1$
2. O — $\sigma(z) = 0.5$인 것은 $z = Wx + b = 0$일 때입니다.
3. ② — 선형 출력은 $-\infty$~$+\infty$라 확률이 될 수 없습니다.
4. ② — $-\log 0.1 \approx 2.30$
5. 0.5
6. 주둥이 길이 ($w_2 = +3.57$)
7. 예시 답: 정답이 1이면 $-\log H$, 0이면 $-\log(1-H)$로, 정답과 반대쪽으로 확신할수록 손실이 커진다. 강아지에게 "강아지일 확률 0.1"이라고 하면 2.30, 0.9라고 하면 0.11이다.

## 04-02 nn.Module과 클래스로 구현하는 로지스틱 회귀

1. O
2. X — 결정 경계가 직선이라 직선으로 나뉘지 않는 범주는 분류할 수 없습니다.
3. ①
4. ②
5. 2
6. 소프트맥스
7. 예시 답: 모델은 특성의 선형 결합으로만 판단하므로, 범주를 가르는 정보가 특성에 없으면 분류하지 못한다. 퍼그는 주둥이가 짧아 몸무게·주둥이만으로는 고양이와 구분되지 않는다.

# 용어 정리

| 용어 | 정의 |
|---|---|
| 이진 분류 | 입력을 두 범주 중 하나로 정하는 문제. 레이블 $y \in \{0, 1\}$ |
| 특성 (feature) | 입력을 이루는 각각의 값 (예: 몸무게, 주둥이 길이) |
| 시그모이드 함수 | $\sigma(z) = 1/(1+e^{-z})$. 실수를 (0, 1)로 옮기는 S자 함수 |
| 로지스틱 회귀 | 가설 $H(x) = \sigma(Wx+b)$로 $P(y=1 \mid x)$를 예측하는 이진 분류 모델 |
| 결정 경계 | $Wx + b = 0$인 집합. 두 범주가 갈리는 경계 |
| 이진 크로스 엔트로피 (BCE) | $-[y \log H + (1-y)\log(1-H)]$. 로지스틱 회귀의 손실 함수 |
| 국소 최솟값 (local minimum) | 전체 최솟값이 아닌, 주변보다만 낮은 지점 |
| 추론 (inference) | 학습된 모델로 처음 보는 입력의 예측을 얻는 것 |